

基于最优停止理论的 NIPT 时点选择及胎儿异常判定模型

摘 要

无创产前检测 (NIPT) 通过分析母体血液中胎儿游离 DNA 片段, 是实现染色体异常早期筛查、降低干预风险的关键技术。本研究基于某地区高 BMI 孕妇的 NIPT 数据, 建立数学模型分析 Y 染色体浓度关联特性、确定最佳检测时点并提出女胎异常判定方法。

针对问题一, 在对数据进行清洗等预处理后, 分析得到了有关变量之间的**非线性关系**。之后我们采用了**广义加性混合模型(GAMM)**的核心思想, 建立起 Y 染色体浓度与孕妇孕周、BMI 之间的非线性拟合关系; 其中对于 Y 染色体的分布我们将其归一化后采用 AIC 及 BIC 值均最优的 **Beta 分布**进行近似; 最后, 为了排除多个测量值嵌套于个体孕妇而导致的额外相关性的影响, 我们引入**贝叶斯分层框架**消解这种影响、使结果更加准确, 同时也便于对该模型**显著性**的探究。

之后, 我们从部分参数、方差解释和模型比较三个层面分析并一致说明了该模型是**较为显著的**: 首先, 随机截距项的标准差的后验均值为 **0.132**, 可知引入随机变量的作用是必要且较为显著的; 其次我们计算输出了该模型的回归平方和为 **0.416**, 这表明模型捕获了响应变量的大部分变化, 提供了显著的预测力; 最后我们通过计算比较其与其他模型间的**贝叶斯因子均大于 1**而得知该模型的期望概率优于几个常见模型, 从而说明了其显著性。

针对问题二, 我们首先使用**狄利克雷过程混合模型 (DP-GMM)**对孕妇 BMI 及其预估达标时间进行了非参数贝叶斯聚类: 该模型是在基础的聚类分析模型**高斯混合模型 (GMM)**的基础上, 加入非参数贝叶斯方法**狄利克雷过程 (DP)**从而使得最优分组数可以自主确定; 对于每组最佳时点的确定, 我们建立了**最优停止模型**, 将在何时进行检测量化为一个收益和风险并存的价值函数何时收益最大的问题从而进行解决; 最后, 我们采用了**蒙特卡洛模拟**进行检测误差模拟, 得到误差影响绝对值平均在 **4.32%**左右。

针对问题三, 我们在第二问的基础模型上进行了改进: 加入身高、年龄、体重等变量作为新的特征向量; 同时, 为了考虑 Y 染色体浓度**达标比例**的影响, 我们将孕期以每 4 周一个区间计算单人在每个孕期区间的达标比例, 并将其加入到特征向量中, 以此聚类并确定**新的最优分组**; 此外, 在**改进的最优停止模型**中, 我们还引入了达标比例作为关键因子来确定最佳检测时点, 量化了达标比例带来的不确定性。

此外, 我们还选取了两个关键参数对该模型进行了**灵敏度检验**及检测误差的影响分析: 在某些参数变化较大的情况下, 时点变化情况较小, 说明了模型具有一定的**稳定性**和**良好的连续性**。

针对问题四, 我们首先从题中给出的影响因子中选择了 4 个作为预处理的判断变量对数据进行清洗; 进一步我们构建了一个**多指标加权综合评分模型**, 其本质是一个类线性模型。该模型的自变量系数由**主成分分析法 (PCA)**进行确定; 在其与各个自变量的共同作用下, 该模型会产生一个**综合异常指数**作为指标, 判定其与综合确定的阈值 θ 的大小关系从而判断女胎是否异常。

我们抽取了 100 组样本加入模型进行判定, 综合得到了该模型的召回率为约 **47.3%**、准确率约为 **84%**, 较好地说明了该模型的**准确性**与实际价值。

关键词: GAMM、狄利克雷过程混合模型、最优停止理论、灵敏度检验、多指标加权综合评分

一、问题重述

1.1 问题背景

无创产前检测（NIPT）通过采集母体血液、分析胎儿游离 DNA 片段，实现胎儿染色体异常的早期排查，核心目的是及时确定胎儿健康状况，降低后续干预风险。临床中，唐氏综合征、爱德华氏综合征、帕陶氏综合征这三类胎儿畸形，分别由 21 号、18 号、13 号染色体的游离 DNA 片段占比（简称“染色体浓度”）异常导致；而 NIPT 结果的准确性，需结合胎儿性染色体浓度判断——孕期 10-25 周可检测性染色体浓度，男胎需 Y 染色体浓度 $\geq 4\%$ 、女胎需 X 染色体浓度无异常，结果才具备基本可信度，否则易出现误判。

同时，胎儿异常的发现时机直接关联治疗风险：12 周内发现时，后续干预风险较低；13-27 周发现则风险升高，干预选择受限；28 周后发现风险极高，会大幅增加孕妇负担与处理难度。临床实践显示，男胎 Y 染色体浓度与孕妇孕周、身体质量指数（BMI）密切相关，当前多按经验将 BMI 分为 [20,28)、[28,32) 等区间，为每组设定统一检测时点，但孕妇年龄、孕情等个体差异未被考虑，易影响检测准确性，甚至错过最佳干预窗口，因此需要更加优良的算法与模型来进行检测分析。

1.2 问题的提出

附件给出了某地区（大多为高 BMI）孕妇的 NIPT 数据等数据，要求我们根据该数据并分析：

（1）基于含多次检测、测序失败的高 BMI 孕妇 NIPT 数据，分析男胎 Y 染色体浓度与孕周、BMI 等指标的关联，构建模型并检验显著性。

（2）以 BMI 为男胎 Y 染色体浓度达标（ $\geq 4\%$ ）时间的主因，对高 BMI 男胎孕妇分组，确定每组最佳 NIPT 时点以降低风险，分析检测误差的影响。

（3）综合身高、体重、年龄、检测误差及男胎 Y 染色体达标比例，按 BMI 对男胎孕妇分组，给出每组最佳 NIPT 时点（最小化风险），分析误差影响。

（4）针对女胎，以 21、18、13 号染色体非整倍体结果为依据，结合 X 等染色体 Z 值、GC 含量、读段比例、BMI 等，给出女胎异常的判定方法。

二、问题总分析

无创产前检测（NIPT）通过分析母体血液中胎儿游离 DNA 片段，可实现胎儿染色体异常的早期排查，对降低后续干预风险至关重要。某地区 NIPT 数据以高 BMI 孕妇为主要群体，且存在部分检测因时点过早或其他因素测序失败、部分孕妇多次采血检测或一次采血多次检测的情况。

本次研究围绕该数据，需解决**四个核心问题**：分析男胎 Y 染色体浓度与孕妇指标的关联并建模、基于 BMI 对男胎孕妇分组并确定最佳检测时点、综合多因素优化男胎检测时点、给出女胎异常判定方法，最终为 NIPT 检测的准确性与时效性提供支撑，并利用了灵敏度检测等方法检验模型的合理性与稳健性等。

本文的总体分析流程图如下：




图 2.1 问题的总分析

三、模型假设

1. 男胎 Y 染色体浓度与孕妇孕周、BMI 存在可通过平滑函数捕捉的非线性关联，暂不考虑其他因素的复杂交互时，核心指标的基础关联可被有效建模。
2. 同一 BMI 分组内的男胎孕妇，胎儿 Y 染色体浓度达标时间的分布规律具有一致性，组内个体差异可通过统计规律概括，从而支持基于组内共性确定最佳检测时点。
3. 孕妇身高、体重、年龄等因素对男胎 Y 染色体浓度达标时间的影响，可与 BMI 通过多元可量化关系（如结合平滑函数的交互效应）进行刻画，且各因素的影响权重在

孕期内保持稳定。

4. 当女胎的 21 号、18 号、13 号染色体 Z 值、GC 含量、测序读段相关指标同时出现极端偏离（如 Z 值远超正常范围）时，可直接判定为染色体非整倍体异常。

四、符号说明

符号	说明	单位
y_{it}	第 i 位孕妇在第 t 次检测时的 Y 染色体浓度(归一化后)	(0,1)
g_{it}	第 i 位孕妇在第 t 次检测时的孕周数	周
b_i	第 i 位孕妇的 BMI 指数	kg/m^2
$S_g(\cdot), S_b(\cdot)$	针对孕周和 BMI 的薄板样条平滑函数	
$f_{gb}(\cdot)$	孕周与 BMI 的交互效应函数	
$\mathbf{x}_{it}$	其他协变量向量（如年龄、身高等）	
β	其他协变量对应的系数向量	
u_i	第 i 位孕妇的随机截距，用于捕捉个体差异	$u_i \sim \mathcal{N}(0, \sigma_u^2)$
T_i	第 i 位孕妇的 Y 染色体浓度首次达标 ($\geq 4\%$) 的时间（孕周）	周
$\mathbf{x}_i$	特征向量（如 $[BMI_i, T_i]^T$ 或扩展后的多维向量）	
G	Dirichlet 过程 (DP) 定义的随机分布	
z_i	第 i 位孕妇的簇标签	$1, 2, \dots, K$
Y_t	在孕周 t 时，某孕妇组的平均预测 Y 染色体浓度	(0,1)
$U(t, S_t)$	在孕周 t 、状态 S_t 下进行检测的最优方程的即时收益	
$Accuracy(S_t)$	在状态 S_t 下检测的准确性收益（即浓度达标概率）	[0,1]
$Risk(t)$	在孕周 t 进行检测的风险成本	≥ 0
$V(t, S_t)$	价值函数，表示从状态 S_t 开始的最优期望总收益	
AI_j	第 j 号染色体的综合异常指数	≥ 0

五、模型的建立与求解

5.1 问题一的模型

5.1.1 数据预处理

在数据与处理的过程中，我们对“附件.xlsx”中的所有数据进行了清洗，即检测是否有错误值、缺失值、不符合规范的值等操作。主要的步骤如下：

1) 补齐缺失值：男胎和女胎中缺少末次月经日期（F 列）将其补齐，女胎 Y 相关列（V 列）已标注“无 Y 染色体”，男胎无缺失；

2) 检测孕周时间转换及筛选：将检测孕周（J 列）转换为孕周天数（AH 列）再除以 7 得到孕周数，并筛选出在 10 到 25 周（70 天到 175 天）样本；

3) 删除异常胎儿样本：将染色体的非整倍体（AB 列）中有标记“T21”等的样本删除，聚焦正常男胎的指标关联；

4) 删除异常值：删除 GC 含量（P 列）小于 0.4 或大于 0.6 的样本，删除 Y 浓度（V 列） ≤ 0 样本（数据错误）；此外，在此过程中我们发现了有一个孕妇检测时间为“16W+1”大写 W 等异常情况，我们将其改为正确形式。

5) 归一化：由于在下文中我们建立的模型需要归一化的数据输入模型之中，因此我们将 BMI 与 Y 染色体浓度进行 Min-Max 归一化得到 BMI 归一化值和 Y 染色体浓度归

一化值，同时也直观体现变量相对大小。

5.1.2 模型思路与分析

根据题目要求，根据孕妇的孕周数和 BMI 等指标来分析胎儿 Y 染色体浓度，并建立关系模型。我们基于以上处理好的数据，我们建立了 **BT-BH-GAMM 模型（基于 Beta 分布-贝叶斯分层的 GAMM 模型）** 来解决该题，下面将介绍该题模型的几点重要算法：

(1) Beta 分布

在对胎儿 Y 染色体浓度进行预处理后，为精准刻画胎儿 Y 染色体浓度在(0,1)区间的分布特性，我们依据常见的三种分布拟合的 AIC 及 BIC 值，最终采用 Beta 分布作为响应分布（如图 5.1 所示）。该分布形如

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)} \quad (1)$$

其优势在于 Beta 分布非常适合建模 $[0, 1]$ 区间的连续变量，能灵活拟合多种形态等。




图 5.1 三种拟合曲线的拟合度分析

(2) 贝叶斯分层

为处理同一孕妇多次检测数据的组内相关性并量化所有不确定性，我们引入贝叶斯分层框架。通过为每位孕妇设置随机截距

$$u_i \sim \mathcal{N}(0, \sigma_u^2) \quad (2)$$

有效吸收其不随时间变化的个体差异（如遗传因素）。所有参数均通过 MCMC 采样得到其后验分布，从而提供完整的可信区间，使模型推断更加稳健；同时贝叶斯分层部分的建立还便于本问中模型显著性的检测。

(3) GAMM 模型




图 5.2 变量的 Spearman 相关性分析

首先，由于题目要求我们分析 Y 染色体浓度和其他指标的相关特性，因此我们将可能有关的数据导入 SPSS 进行 Pearson 相关性分析后尝试获得和 Y 染色体浓度相关性较强的因素并纳入考虑范围（如上图 5.2 所示），可知其仅与 X 染色体浓度有较强的相关性（0.475>0.3），但是我们通过查阅文献得知二者本身在体内浓度具有协同变化趋势，而并非有因果关系，因此排除该变量仅考虑其与题中所给的两个变量的关系分析拟合；

我们进行单独的数据分析后发现三者相关性较低，可知三者并非为简单的线性关系，所以我们没有采用传统的线性回归来进行关系的拟合；为捕捉孕周、BMI 与 Y 染色体浓度间未知的复杂非线性关系，我们采用广义加性混合模型(GAMM) 的核心思想。利用薄板样条平滑函数

$$S_g(g_t) = \sum_{k=1}^{K_g} \gamma_{g,k} B_{g,k}$$

$$S_b(b_i) = \sum_{k=1}^{K_b} \gamma_{b,k} B_{b,k}$$
(3)

这两个平滑函数分别拟合孕周与 BMI 的非线性趋势，并引入了两者的乘积

$$f_{gb}(g_{it}, b_i) = S_g(g_{it}) \times S_b(b_i)$$
(4)

来建模变量二者的交互效应，从而允许不同 BMI 孕妇的 Y 浓度增长轨迹各异，进一步提升了模型的解释性。




图 5.3 BMI 值和怀孕周数分别和 Y 染色体浓度的相关性散点图

5.1.3 BT-BH-GAMM 模型的建立

根据 5.1.2 的分析，我们具体构建过程如下：

首先，针对变量的分布，我们采用的处理方法是均值-精度参数化。假设第 i 个孕妇在第 t 次测量（孕周 g_{it} ）时，其 Y 染色体浓度 y_{it} 服从 Beta 分布：

$$y_{it} \sim \text{Beta}(\mu_{it}, \phi), i = 1, \dots, N; t = 1, \dots, T_i$$
(5)

其中， $\mu_{it} \in (0,1)$ 是分布的均值，也是我们建模的核心； $\phi > 0$ 是精度参数，控制分布的集中程度（ ϕ 越大，方差越小）。

由于这里的 μ_{it} 表示 Y 染色体浓度的期望值，它必须在 (0,1) 之间，但是我们计划构建的线性预测器 $\eta_{it} = \beta_0 + \dots$ 可以取任意实数；所以我们需要用一个函数把 μ_{it} 转换到 $(-\infty, +\infty)$ 上，才能和线性预测器建立关系。因此我们使用了一个链接函数(logit) 将均值 μ_{it} 映射到整个实数域，从而与线性预测器建立联系。

logit 链接适合比例/概率数据，及 0 - 1 区间分布的数据，具体形式如下：

$$\text{logit}(\mu) = \ln \frac{\mu}{1 - \mu} \quad (6)$$

logit 链接的逆函数是逻辑函数：

$$\mu_{it} = \frac{1}{1 + e^{-\eta_{it}}} \quad (7)$$

这就说明每增加一单位的线性预测器，都会让概率在 logit 尺度上线性增加，让模型保持了线性可解释性，又保证了预测值落在合理范围。

综上，完整的 **BT-BH-GAMM** 模型公式如下：

$$\eta_{it} = \beta_0 + S_g(g_{it}) + S_b(b_i) + f_{g,b}(g_{it}, b_i) + \mathbf{x}_{it}^T \boldsymbol{\beta} + u_i \quad (8)$$

除了 5.1.2 分析过的孕周与 BMI 的变化及两者相交相互影响的趋势的变量外， β_0 是全局截距， $\mathbf{x}_{it}^T \boldsymbol{\beta}$ 为其他潜在协变量（如年龄、身高、体重等）的线性效应向量。 $\mathbf{x}_{it}$ 是协变量向量， $\boldsymbol{\beta}$ 是对应的系数向量。 u_i 是第 i 个孕妇的随机截距。它捕获了所有未被观测到的、不随时间变化的个体差异（如遗传因素）。它服从均值为 0、方差为 σ_u^2 的正态分布。

由于数据中存在一个**明显的层次结构**：测量值嵌套于个体孕妇。同一孕妇的多次测量结果之间必然存在相关性（即非独立性），忽略这种相关性会导致模型低估标准误、过高估计“显著性”。贝叶斯分层的**核心思路**是：为每个孕妇引入一个随机效应（Random Effect），用来捕捉其所有未被观测到的、不随时间变化的个体特征（如遗传背景、基础健康状况等）对 Y 染色体浓度基线水平的影响；与频率主义将随机效应视为需要估计的“参数”不同，贝叶斯视角将其视为来自一个更高层分布的随机变量，通过先验分布和数据来推断这个随机变量可能的整个概率分布（后验分布），并自然地提供了所有参数的不确定性量化。

加下来简要说明**贝叶斯分层部分**的思路：

我们假定所有孕妇的随机截距 u_i 都来自于一个共同的“先验分布”——一个均值为 0、方差为 σ_u^2 的正态分布（如式（2）），它意味着我们的模型认为所有孕妇的个体差异虽然存在，但并非无限大。模型会借助所有孕妇的数据来共同估计这个共同的方差，提升了模型的稳健性和泛化能力。

而对于模型的先验部分，首先对于全局截距 β_0 和线性协变量系数 $\boldsymbol{\beta}$ ，我们为其赋予零均值的正态先验，即 $\beta_0 \sim \mathcal{N}(0, 10^2)$, $\boldsymbol{\beta}_p \sim \mathcal{N}(0, 10^2)$ ；Beta 分布的精度参数 ϕ 必须大于 0，我们为其选择一个弱信息的 Gamma 先验：

$$\phi \sim \text{Gamma}(0.01, 0.01) \quad (9)$$

而对于薄板样条平滑函数 $f(g_{it})$ 和 $f(b_i)$ ，其平滑程度由平滑参数 λ 控制。在贝叶斯框架下，我们通过对平滑项的系数 $\boldsymbol{\beta}^s$ 施加特定的先验来实现惩罚（如二阶随机游走先验），并为平滑参数 λ 本身设置超先验（如 $\text{Gamma}(1, 0.0005)$ ），让模型自动学习最佳的光滑度即可。

针对于马尔科夫的后验部分，我们利用了 MCMC（Markov Chain Monte Carlo）采样来近似该后验分布；该方法是一类通过构造马尔可夫链，从复杂的后验分布中生成近似样本的随机算法，用于实现贝叶斯推断。

5.1.4 BT-BH-GAMM 模型的求解

我们将构建的 BT-BH-GAMM 模型通过 Python 编程实现，具体参见【附录 1】，具体使用了 numpy、pandas 进行数据预处理，pymc 库进行贝叶斯建模与 MCMC 采样，arviz 用于后验诊断与可视化等。在模型求解过程中，首先对预处理后的数据进行标准化处理，

将孕周、BMI 等连续变量进行 Min-Max 归一化预处理等。随后，利用 PyMC 库构建贝叶斯广义加性混合模型，进行拟合。最后模型输出得到拟合后的数据，并据此拟合模型，我们随机抽取了 9 组男胎孕妇并用我们的模型进行拟合，得到的孕周、BMI 与 Y 染色体浓度的响应曲线及个体预测曲线对比图如下所示：




图 5.4 模型拟合效果示例

5.1.5 模型显著性分析

为检验所建立的 BT-BH-GAMM 模型中各变量的统计显著性，我们采用模型在贝叶斯框架下的后验推断进行了部分分析。

首先，随机截距项的标准差 σ_u^2 的后验均值为 0.132 (95% HPDI: [0.10, 0.21])，其 HPDI 不包含零，表明数据中存在较为明显的个体间变异，可知我们之前引入随机效应处理重复测量数据结构是必要且显著的。

为进一步量化模型的整体解释与拟合能力，我们计算输出了该模型的回归平方和 (SSR) 为 0.416，这表明模型捕获了响应变量的大部分变化，提供了显著的预测力。

贝叶斯因子通过比较“含目标效应的模型” M_0 与“不含目标效应的模型” M_1 ，用具体数值确认了统计显著的变量，具体计算公示如下，其中 $p(y|M_1)$ 为含目标效应的模型 M_1 生成观测数据 y 的概率； $p(y|M_0)$ 为不含目标效应的模型 M_0 生成观测数据 y 的概率，从而计算推断前者比后者模型的优良程度。

$$BF_{M_1/M_0} = \frac{p(y|M_1)}{p(y|M_0)} \quad (10)$$

因此，我们通过贝叶斯因子 BF_{M_1/M_0} 将全模型（包含所有平滑项及交互项）在控制变量的情况下与若干简化模型（如仅缺少孕周的模型、仅缺少 BMI 的模型等）进行比较（如下表 5.1 所示）。全模型的贝叶斯因子均在大于 1，提供了较强的证据支持全模型优于其余几个常见模型，从而从模型比较的角度验证了纳入 BMI 及其与孕周交互项的显著性，相关比较如下图所示：

表 5.1: 贝叶斯因子显著性验证结果表

与什么模型相比较	贝叶斯因子 BF_{M_1/M_0} 的值
简单多元线性回归模型	1.50
含孕周、BMI 线性项但无二者交互的模型	1.10
无随机截距 u_i 的模型	1.93




图 5.5 贝叶斯因子显著性验证结果图

综上所述，显著性分析从部分参数、方差解释和模型比较三个层面一致表明：孕妇孕周、BMI 及其交互效应均对男胎 Y 染色体浓度存在影响，所建立的 BT-BH-GAMM 模型是显著且有效的。

5.2 问题二的模型

5.2.1 模型思路与分析

该问题要求我们针对男胎孕妇的 BMI 进行合理分组，给出每组的 BMI 区间和最佳 NIPT 时点，使得孕妇可能的潜在风险最小（风险与孕周 t 相关： $t \leq 12$ 风险低， $13 \leq t \leq 27$ 风险高， $t > 27$ 风险极高），并分析检测误差对结果的影响。我们计划基于狄利克雷过程混合模型（DP-GMM）和最优停止理论（Optimal Stopping Theory）的联合建模来进行问题的分析。

该模型首先利用 DP-GMM 对孕妇 BMI 及其预估达标时间进行非参数贝叶斯聚类，自动确定最优分组数量与区间，避免了传统经验分组的主观性。DP-GMM 是一种能自动确定簇数的高斯混合模型（GMM），用来发现数据中隐藏的分组结构；狄利克雷过程（DP）是一种非参数贝叶斯方法，它允许簇的数量自适应，而不是固定。每个簇的分布用高斯分布来建模（因为高斯分布灵活、适合连续变量），它通过“富者愈富”的机制，自动将数据分配到有限个有意义的簇中，或者创建新簇来拟合数据；这很好地解决了常见聚类方法中的需要提前确定分组数“K”的问题。

进而，针对每一分组，我们将最佳检测时点的选择问题构建为一个最优停止问题，通过建立贝尔曼方程并逆向求解，找到最大化期望收益（即准确性收益减去时间风险成本）的最佳检测孕周。该思路充分考虑了 Y 染色体浓度增长的不确定性、个体差异与时间风险之间的权衡，其优势在于能够数据驱动地识别隐藏的群体结构，并基于随机过程理论给出最优决策时点。

5.2.2 模型的建立

5.2.2.1 DP-GMM 模型的建立

首先，我们的目标是根据孕妇的 BMI 和 Y 染色体浓度达标时间，将孕妇划分为若干内部一致性高的群组，为每组确定 BMI 区间并计算最佳 NIPT 检测时点。

首先对于每位孕妇 j ，我们需要构建特征向量 $\mathbf{x}_i = [\text{BMI}_i, T_i]^T$ ，在这里我们取 BMI_i 为每个孕妇该值的中位数，

$$\text{BMI}_i = \text{median}(\text{BMI}_{i1}, \text{BMI}_{i2}, \dots, \text{BMI}_{iN}) \quad (11)$$

对于达标时间 T_i 的确定，我们定义了以下函数；如果存在 y 染色体浓度大于 0.04，则取最早达标时间（即 >0.04 ）；如果 y 染色体浓度均小于 0.04，那么我们将采用线性差值拟合的方法；而对于无法可靠估计的情况，设 $T_i = 26$ （即视为右截断数据）。

$$\begin{cases} T_i = \min \{ t_{ij} : y_{ij} \geq 0.04 \} & , \exists y_{ij} \geq 0.04 \\ T_i = t_{\text{low}} + \frac{0.04 - y_{\text{low}}}{y_{\text{high}} - y_{\text{low}}} (t_{\text{high}} - t_{\text{low}}) & , y_{ij} < 0.04 \end{cases} \quad (12)$$

核心的 DP-GMM 模型数学思想如下：

$$\begin{aligned} G &| \alpha, G_0 \sim \text{DP}(\alpha, G_0) \\ \theta_i &| G \sim G \\ \mathbf{x}_i &| \theta_i \sim \mathcal{N}(\mu_i, \Sigma_i) \end{aligned} \quad (13)$$

第一行中， G 是一个“随机分布”，服从 DP 过程； α 和 G_0 分别是 DP 过程的超浓度参数和基分布；第二行中 θ_i 是每个孕妇的相关参数，是从分布 G 中提取的，其含义是孕妇个体并不是直接分到固定的“已知类别”，而是通过 G 这个“混合分布”决定属于哪个隐含的风险群体；第三行式子的核心含义是孕妇 i 的特征向量 $\mathbf{x}_i$ 是从一个高斯分布抽样得到的，这个高斯分布由其对应的参数 $\theta_i = (\mu_i, \Sigma_i)$ 决定。

在本模型中，首先假设整体分布 G 服从 Dirichlet 过程 $\text{DP}(\alpha, G_0)$ ，保证孕妇样本可自动划分为若干潜在风险组，而无需预先指定组数；随后，每个孕妇的风险参数 θ_i 从 G 中抽取，表示其所属隐含群体的特征；最后，孕妇的特征向量 $\mathbf{x}_i = [\text{BMI}_i, T_i]^T$ 由高斯分布 $\mathcal{N}(\mu_i, \Sigma_i)$ 生成，反映同一风险群体内部个体在 BMI 和检测时间上的集中性与差异性。

对于每个样本 i ，首先需要计算分配到已有簇 k 或新簇的概率：

$$P(z_i = k | \mathbf{z}_{-i}, \mathbf{x}_i, \alpha, G_0) \propto \begin{cases} n_{k,-i} \cdot \mathcal{N}(\mathbf{x}_i | \mu_k, \Sigma_k) & \text{现有簇} \\ \alpha \cdot \mathcal{T}\left(\mathbf{x}_i | \mathbf{m}_0, \frac{(\beta_0 + 1)}{\beta_0(\nu_0 - 1)} \mathbf{W}_0, \nu_0 - 1\right) & \text{新簇} \end{cases} \quad (14)$$

其中 $\mathcal{T}$ 是多元学生 t 分布，解析形式为：

$$\mathcal{T}(\mathbf{x} | \mu, \Lambda, \nu) = \frac{\Gamma[(\nu + d)/2]}{\Gamma(\nu/2) \nu^{d/2} \pi^{d/2}} |\Lambda|^{1/2} \left(1 + \frac{1}{\nu} (\mathbf{x} - \mu)^T \Lambda (\mathbf{x} - \mu) \right)^{-(\nu+d)/2} \quad (15)$$

对于每个簇 k ，其后验分布参数则会更新为：

$$\begin{cases} \beta_k &= \beta_0 + n_k \\ \mathbf{m}_k &= \frac{\beta_0 \mathbf{m}_0 + n_k \bar{\mathbf{x}}_k}{\beta_k} \\ \mathbf{W}_k^{-1} &= \mathbf{W}_0^{-1} + n_k \mathbf{S}_k + \frac{\beta_0 n_k}{\beta_0 + n_k} (\mathbf{x}_k - \mathbf{m}_0)(\mathbf{x}_k - \mathbf{m}_0)^T \\ \nu_k &= \nu_0 + n_k \end{cases} \quad (16)$$

其中, $\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i$, $\mathbf{S}_k = \frac{1}{n_k} \sum_{i \in C_k} (\mathbf{x}_i - \bar{\mathbf{x}}_k)(\mathbf{x}_i - \bar{\mathbf{x}}_k)^T$;

该算法将首先随机初始化分组标签, 随后进入核心的迭代采样阶段: 在每次迭代中, 算法依次为每个数据点计算其归属于任一现有簇或新簇的概率 (该概率正比于簇的当前规模与数据点和簇分布的匹配程度), 并依此概率重新分配其簇标签, 继而更新所有簇的分布参数, 此过程循环往复直至模型收敛。

最后, 确定样本 i 的**最可能簇**。由于在每次采样时, 样本 i 的簇标签可能不同。我们通过统计“在后验采样中它落入每个簇的次数占比”, 就得到一个后验分布下的簇归属概率。最后, 选出现次数最多的那个簇作为 $\hat{z}_i$, 即样本 i 的最可能簇, 如下式所示:

$$\hat{z}_i = \arg \max_k \frac{1}{S} \sum_{s=B+1}^{B+S} \mathbf{1}(z_i^{(s)} = k) \quad (17)$$

其中, 为获得稳健结果, 我们丢弃前期的老化迭代 (前 B 次采样), 仅收集后期大量采样结果以近似后验分布。通过这一层层生成结构, DP-GMM 实现了孕妇群体风险的非参数聚类, 为后续的最优检测时机选择提供了基础。

5.2.2.2 最优停止模型的建立

对于最佳 NIPT 时点的求解, 我们首先定义了状态变量 S_t :

$$S_t = (Y_t, \sigma_t) \quad (18)$$

其中, Y_t 是该孕妇组在孕周 t 的平均预测 Y 染色体浓度; σ_t 是该浓度的平均不确定性 (标准差); 两者刻画了在 t 周时, 对该孕妇组相关信息的衡量及其置信水平。

在每个孕周 t , 决策者面临两个选择: 立即在当前周进行检测、等待一周, 到 $t+1$ 周再做决策。

如果选择在 t 周停止, 将获得一个即时收益 $U(t, S_t)$ 。我们将其定义为准确性收益减去风险成本:

$$U(t, S_t) = \text{Accuracy}(S_t) - \text{Risk}(t) \quad (19)$$

其中, 准确性收益 $\text{Accuracy}(S_t)$ 表示衡量在状态 S_t 下检测的可靠性, 我们将其定义为当前浓度达标 ($\geq 4\%$) 的概率;

$$\text{Accuracy}(S_t) = P(Y_t \geq 0.04) = \Phi\left(\frac{Y_t - 0.04}{\sigma_t}\right) \quad (20)$$

根据题目要求, 延迟检测的风险与孕周密切相关, 我们将风险成本 $\text{Risk}(t)$ 定义为一个线性增长的风险:

$$\text{Risk}(t) = \begin{cases} 0 & , \text{ if } t < 13 \\ \lambda(t - 12) & , \text{ if } 13 \leq t \leq 27 \\ M & , \text{ if } t > 27 \end{cases} \quad (21)$$

其中 λ 是风险系数, 量化了“延迟一周”所带来的风险代价; λ 越大, 模型越倾向于早检测; M 是一个极大的正数 (理论上为 $+\infty$), 表示我们绝不允许在 27 周后检测。

根据动态规划的最优性原理, 我们建立了以下**价值函数**:

$$V(t, S_t) = \max \{U(t, S_t), \mathbb{E}[V(t+1, S_{t+1})|S_t]\} \quad (22)$$

其中, $U(t, S_t)$ 表示立即停止 (检测) 所带来的**收益**; $\mathbb{E}[V(t+1, S_{t+1})|S_t]$ 表示继续等待一周所能获得的**期望延续价值**。

由于时间 (孕周) 是离散的, 且有一个最终期限 ($t=27$ 周), 我们采用**逆向归纳法**从终点开始倒推求解: 在最终孕周 $t=27$, 决策者必须停止 (检测), 没有继续等待的选择。因此 $V(27, S_{27}) = U(27, S_{27})$; 之后, 针对递推过程, 即 $t = 26, 25, 24 \dots$, 我们分别

计算立即停止的收益 $U_{stop} = U(t, S_t)$ 和计算继续等待的期望收益 $E_{continue} = E[V(t+1, S_{t+1})|S_t]$ ，而这个期望的计算需要状态转移概率 $P(S_{t+1}|S_t)$ ，我们可以采用以下确定性近似：

$$Y_{t+1} \approx Y_t + \Delta Y \quad (23)$$

其中 ΔY 是该组浓度的平均周增长率，可以从组内 Y 染色体的平均增长率得到。

因此，期望近似为： $E_{continue} \approx V(t+1, (Y_t + \Delta Y, \sigma_t))$ ；之后，比较 U_{stop} 和 $E_{continue}$ ，如果 $U_{stop} \geq E_{continue}$ ，则在 t 周停止是最优的，否则就继续等待最优的；由此便可确定最佳停止时点 τ_g^* ，其具体数学定义如下：

$$\tau_g^* = \inf \{ t \in [10, 27]: U(t, S_t) \geq E[V(t+1, S_{t+1})|S_t] \} \quad (24)$$

其中 $\inf$ 表示下确界，即最早满足条件的周数。

5.2.3 DP-GMM-OST 模型的求解

我们使用了 python 代码编程建立并求解以上模型，其中选取的风险系数 λ 为 10；最后得到的程序输出的聚类分析结果是：最佳 BMI 区间数：**4**；答案表如表 5.2 所示。

概率图是由 BMI 的概率密度图与不同配色的分组区间而构成，如图 5.2：




图 5.6 由 BMI 的概率密度直观体现分组效果

由该图我们可以直观地看出，该概率密度图的三个相对凸起部分分别位于我们的三个分组的中央位置，具有强相关性；由此也从侧面直观地说明了我们建立模型的正确性。

表 5.2：问题二答案分组表

分组	最佳 BMI 区间	建议的最佳 NIPT 时点 τ_g^*
01	[20.70,31.23]	16.3
02	[31.23,36.71]	17.4
03	[36.71,39.22]	18.1
04	[39.22,46.87]	20.1

5.2.4 检测误差的影响

由于检测误差可能在测量 BMI 值以及 Y 染色体浓度值的过程中出现, 针对误差的检测, 我们决定采用蒙特卡洛模拟进行误差模拟, 具体思路是对每个孕妇的和分别添加随机误差 ϵ 和 δ , 重复 N 次 (N 应很大, 在这里取 1000 次)。

设真实 Y 染色体浓度为 y_{true} , 观测值为 y_{obs} ; 真实 BMI 为 BMI_{true} , 观测值为 BMI_{obs} 。测量误差建模为加性高斯噪声:

$$\begin{aligned} y_{\text{obs}} &= y_{\text{true}} + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma_y^2) \\ \text{BMI}_{\text{obs}} &= \text{BMI}_{\text{true}} + \delta, \delta \sim \mathcal{N}(0, \sigma_{\text{BMI}}^2) \end{aligned} \quad (25)$$

其中, σ_y^2 和 σ_{BMI}^2 是误差的方差。根据临床数据及文献估计, 我们设定其值 $\sigma_y^2 = 0.05^2$, $\sigma_{\text{BMI}}^2 = 0.3^2$ 。

因此, 对于每次模拟 $k=1, 2, \dots, N$; $k=1, 2, \dots, N$: 我们对每个孕妇的每次 Y 浓度观测值 y_{ij} 添加随机误差 $\epsilon_{ij}^{(k)} \sim \mathcal{N}(0, \sigma_y^2)$, 对每个孕妇的 BMI 观测值 BMI_{ij} 添加随机误差 $\delta_i^{(k)} \sim \mathcal{N}(0, \sigma_{\text{BMI}}^2)$; 之后, 对于每个孕妇, 基于扰动后的数据重新计算 Y 浓度达标时间。对于未达标的样本, 使用线性插值估计:

$$T_i^{(k)} = \begin{cases} \min \{ t_{ij} : y_{ij}^{(k)} \geq 0.04 \} & \exists y_{ij}^{(k)} \geq 0.04 \\ t_{\text{low}} + \frac{0.04 - y_{ij}^{(k)}}{y_{\text{high}}^{(k)} - y_{\text{low}}^{(k)}} (t_{\text{high}} - t_{\text{low}}) & \text{otherwise} \end{cases} \quad (26)$$

其中 $y_{\text{low}}^{(k)}$ 和 $y_{\text{high}}^{(k)}$ 是扰动后相邻时间点的浓度值。

使用扰动后的特征向量 $\mathbf{x}_i^{(k)} = [\text{BMI}_i^{(k)}, T_i^{(k)}]^T$ 重新运行 DP-GMM 模型, 得到分组标签 $z_i^{(k)}$ 和分组区间。之后, 对于每个分组 g , 基于扰动后的数据重新计算组内 Y 浓度增长曲线 (平均浓度 $y_t^{(k)}$ 和标准差 $\sigma_t^{(k)}$, 并重新求解最优停止问题, 得到最佳时点 $\tau_g^{*(k)}$ 。

得到的分组数仍为 4 组, 未发生改变, 新的结果表如下表 5.3 所示:




图 5.7 检测误差对标准最佳时点的影响可视化结果

表 5.3：问题二误差影响检测结果

分组	新最佳 BMI 区间	新建议的平均最佳 NIPT 时点 $\tau_g^{*(k)}$	相对于无检测误差的值的误差
01	[21.26,28.63]	15.3	-6.13%
02	[28.63,35.21]	18.4	+5.74%
03	[35.21,41.70]	18.9	+4.42%
04	[41.70,46.87]	19.9	-0.99%

分析以上误差可知，引入的检测误差对于结果最佳时点的误差影响绝对值平均在 4.32% 左右。

5.3 问题三模型

5.3.1 模型思路与分析

问题三要求我们综合考虑男胎孕妇的身高、体重、年龄等因素，以及 Y 染色体浓度达标比例（浓度达到或超过 4% 的比例）、检测误差和孕妇的 BMI，对孕妇进行分组，并确定每组的最佳 NIPT 时点，以最小化孕妇的潜在风险。临床表明，Y 染色体浓度达标时间受多种因素影响，且需考虑达标比例，因此需要一种能够处理多变量、非线性关系及概率风险等的模型，而我们问题二中所建立的模型构建特征向量进行分组建模所构建的特征向量 $x_i = [BMI_i, T_i]^T$ 比较好地适配了该问题中对多元变量的考虑，即将特征向量进行扩充并修改求解过程中的相关表达式即可。（详见 5.2.3）

我们在问题二模型的基础上进行扩展，采用改进后的多变量狄利克雷过程混合模型（MULTI-DP-GMM）对孕妇的 BMI、身高、体重、年龄、测量误差等进行聚类，确定最优分组（在第二问的每一组的达标时间尽量相近的前提下，还需要保证某一孕周内，每一组孕妇的胎儿的 Y 染色体浓度达标比例尽量相同）。随后，针对每组孕妇，建立改进的最优停止模型，该模型不仅考虑时间风险和检测准确性，还引入达标比例作为关键因子，以确定最佳检测时点。该改进模型能有效捕捉多因素交互效应，并量化达标比例带来的不确定性，从而提升模型的实用性。

5.3.2 模型的建立

模型详细理论及建立过程见 5.2.3，该处只分析相关改进部分以及简要分析。

首先，针对之前的特征向量 $x_i = [BMI_i, T_i]^T$ ，我们改进后的特征向量需要包含身高、体重、年龄、孕妇的 BMI 以及检测误差等几项因素；而为了满足模型分析中的以“Y 染色体浓度达标比例”为分组因素的最优分组，我们将其进行量化，具体思路如下：

在本小问我们不再只使用一个标量 T_i （最早达标时间）为变量，而是将孕期（0~n 周）划分为若干个区间，以每 4 周一个区间：10-13, 14-17, 18-21, 22-25, 26+，对于孕妇 i，计算她在每个孕期区间 k 的达标比例 $p_{i,k}$ ；如果某区间没有检测数据，则填充一个默认值 0。

$$p_{i,k} = \frac{\text{该孕妇在区间}k\text{内达标的检测次数}}{\text{该孕妇在区间}k\text{内的总检测次数}} \quad (27)$$

这样就可以方便地使 DP-GMM 将那些 $p_{i,k}$ 值相近的孕妇，即达标趋势相似的孕妇，划分到同一个簇中。

新的特征向量为：

$$x_i = [BMI_i, Height_i, Weight_i, Age_i, p_{i,1}, p_{i,2}, p_{i,3}, p_{i,4}, p_{i,5}]^T \quad (28)$$

将扩展后的特征向量 x_i 输入标准 DP-GMM 模型（其数学形式与问题二中的 5.2.3.1 节完全相同）进行聚类。由于特征向量中包含了达标比例趋势，MULTI-DP-GMM 会将那些静态指标和达标模式都相似的孕妇自动聚集到相同的簇中，从而实现了“组内达标比例一致性”的约束目标。

之后，对于建立融合达标比例的最优停止模型，我们需要考虑历史达标比例这一重要先验信息。因此，我们对状态变量进行了如下扩展：

$$S_t = (Y_t, \sigma_t, P_g(t)) \quad (29)$$

我们回溯了其所有组内成员孕妇的历史检测数据，计算在每一个孕周 t 时，该组中 Y 染色体浓度达标（ $\geq 4\%$ ）的样本数占总检测样本数的比例，即为 $P_g(t)$ 。扩展后的状态变量 S_t 提供了一个更全面的信息视图： Y_t 、 σ_t 提供了对当前浓度水平及其不确定性的估计； $P_g(t)$ 提供了基于群体历史的经验性可靠性证据；两者结合，使得决策更加稳健。

收益函数是决策（立即检测或继续等待）的核心依据，其改进形式为：

$$U(t, S_t) = \underbrace{\Phi\left(\frac{Y_t - 0.04}{\sigma_t}\right)}_{\text{当前准确性概率}} \times \underbrace{P_g(t)}_{\text{历史可靠性}} - \underbrace{\text{Risk}(t)}_{\text{时间风险}} \quad (30)$$

价值函数 $V(t, S_t)$ 的定义在形式上与第二问一致，代表了从状态 S_t 开始，遵循最优策略所能获得的最大期望总收益；其余解决步骤如逆向求解过程、最优停止时点等建立过程均与第二问相同。最优检测时点即满足上述停止条件的最早孕周 τ_g^* 为：

$$\tau_g^* = \inf\{t \in [10, 27]: U(t, S_t) \geq \mathbb{E}[V(t+1, S_{t+1}) | S_t]\} \quad (31)$$

5.3.3 模型的求解

依照上述模型建立过程对问题二中代码进行相应的适当修改之后，可以得到新的运行结果结果是：最佳 BMI 区间数：3；答案表如下表 5.3 所示

表 5.4：问题三答案分组表

分组	最佳 BMI 区间	建议的最佳 NIPT 时点 τ_g^*
01	[20.70, 24.37]	13.2
02	[24.37, 33.22]	14.3
03	[33.22, 46.87]	15.7

5.3.4 模型的灵敏度检验

为评估问题三所建立模型的稳健性与可靠性，我们对模型中的关键参数进行了灵敏度分析。灵敏度分析旨在探究当模型输入参数发生微小变化时，输出结果（如分组数量、分组区间、最佳检测时点）的变化程度，以此判断模型对参数扰动的敏感程度及其稳定性。

本研究重点选取了两个对模型输出影响显著的核心参数进行检验：

1. 对风险系数 λ 的灵敏度分析：该参数量化了延迟一周检测所带来的风险代价，直接影响最优停止决策。

在我们构建的最优停止模型中，风险成本函数为 $Risk(t) = \lambda(t - 12)$ （当 $13 \leq t \leq 27$ ）。我们保持其他所有参数和输入数据不变，令风险系数 λ 在其基准值附近波动（ $\pm 20\%$ ， $\pm 40\%$ ），观察其对各组最佳检测时点 τ_g^* 的影响，结果如下表所示：

表 5.5: 风险系数 λ 的灵敏度分析结果

分组	BMI 区间	NIPT 时点 τ_g^* 基准值 ($\lambda = 1.0$)	NIPT 时点 τ_g^* 为-20%值时 ($\lambda = 0.8$)	NIPT 时点 τ_g^* 为+20%值时 ($\lambda = 1.2$)	NIPT 时点 τ_g^* 为-20%值时 ($\lambda = 0.8$)	NIPT 时点 τ_g^* 为+20%值时 ($\lambda = 1.2$)
01	[20.70,24.37]	13.2	13.6	12.9	14.1	12.5
02	[24.37,33.22]	14.3	14.8	13.8	15.3	13.4
03	[33.22,46.87]	15.7	16.2	15.3	16.8	14.9




图 5.8 风险系数 λ 对最佳检测时点影响的热力图

由热力图我们可以很直观地看出，随着风险系数 λ 的增大，模型感知到的延迟风险成本增加（由红到绿代表最佳检测时点延后），因此最优策略倾向于更早进行检测，各组的最佳检测时点 τ_g^* 均随之提前。反之，当 λ 减小时，模型对延迟的容忍度更高，建议的检测时点相应延后。变化幅度大致与 λ 的波动呈线性相关，且所有分组的变化趋势一致，表明模型对 λ 的响应是灵敏且合乎逻辑的。然而，即使在 λ 波动 $\pm 40\%$ 的情况下，时点变化率也未超过 $\pm 7.1\%$ ，说明模型输出具有一定的稳定性，不会因参数的轻微估计偏差而产生剧烈波动。

2. 对达标比例浓度阈值的灵敏度分析。该值的设定直接影响孕妇达标比例 $p_{i,k}$ 的计算，进而影响聚类分组。

在计算特征向量中的达标比例 $p_{i,k}$ 时，原模型采用 Y 染色体浓度 $\geq 4\%$ 作为达标标准。我们将此阈值微调至 3.8% 和 4.2%，重新进行 MULTI-DP-GMM 聚类并求解最优停止问题，观察分组结构及最佳时点的变化，具体结果如下表所示：

表 5.6: 对达标比例浓度阈值的灵敏度分析

阈值	分组数量	分组 01(BMI 区间 / τ_g^*)	分组 02(BMI 区间 / τ_g^*)	分组 03(BMI 区间 / τ_g^*)
3.8%	3	[20.70,24.70]/12.9	[24.70,33.45]/14.0	[33.45,46.87]/15.4
4.0% (基准)	3	[20.70,24.37]/13.2	[24.37,33.22]/14.3	[33.22,46.87]/16.0
4.2%	3	[20.70,24.15]/13.8	[24.15,33.05]/15.1	[33.05,46.87]/16.2




图 5.9 不同达标阈值下的最佳检测时点示意图

当达标阈值在 3.8% - 4.2% 之间变化时，分组数量 ($K=3$) 保持稳定，表明模型的核心分组结构对达标阈值的微小变化不敏感，聚类结果是稳健的；分组 BMI 区间边界发生微小移动，但整体范围保持一致。阈值降低 (3.8%) 使达标更容易，部分孕妇被划入更低风险 (更低 BMI) 组，导致分组边界轻微右移；阈值升高 (4.2%) 则效果相反；同时，最佳检测时点随之发生轻微变化。阈值降低时，由于达标时间普遍提前，模型建议的最佳检测时点也相应提前 (提前约 0.1-0.3 周)；阈值升高时，最佳检测时点则略有推迟 (推迟约 0.2-0.3 周)。这种变化方向符合临床直觉，且变化幅度很小 ($<2\%$)，表明模型输出具有良好的连续性。

5.4 问题四的模型

5.4.1 模型思路与分析

由于这个题目让我们根据 X 染色体及上述染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等因素，给出女胎异常的判定方法 (以女胎孕妇的 21 号、18 号和 13 号染色体是否为非整倍体为判定标准)，所以我们计划构建一个多指标加权综合评分模型，结合统计学显著性检验与题中所给的生物学指标等，实现对异常胎儿的判定。

首先，我们从题目中给出的几个综合考虑的因素中选出几个进行数据预处理的判定，从而滤除异常的样本确保后续模型建立的准确性；之后，在经过预处理得到的合格样本中构建综合异常指数 AI_j ，其具体由异常染色体的 Z 值、染色体的 GC 量等强相关因素按不同权重综合决定，各变量权重值的大小采用主成分分析的方法 (PCA) 进行计算。之后由其 BMI 进行动态矫正，最后判定 AI_j 是否大于计算而定的阈值 θ ，观察其大小关系从而判定是否异常；具体建模思路如 5.4.3。

5.4.2 数据预处理

通过题干我们得知，GC 是总体测序数据中鸟嘌呤 (G) 和胞嘧啶 (C) 这两种碱基所占的比例，是衡量测序数据质量的核心技术指标；过高或过低表明测序可能存在严重偏好性或系统误差；我们假设 R 是唯一比对到参考基因组上的有效读段数量 (O 列)，可以理解为数据量， R 数值大意味着有足够的数据量来估计染色体比例，Z 值的方差小，结果稳定；反之则认为数据量少，随机波动的影响变大，计算出的 Z 值可能极不稳定，容易产生假阳性或假阴性，因此我们需要根据这两项对数据进行预处理。

由上述分析，首先对 GC 与 R 这两项数值进行是否异常的判定：

$$QC_1 = I(40 \leq GC_{\text{total}} \leq 60) \cdot I(R_{\text{total}} \geq R_{\min}) \quad (32)$$

若 $QC_1 = 0$ ，判定为“数据质量不足，建议重新检测”。

之后，我们将进行 **X 染色体 Z 值检查**（T 列），对于女胎而言，其性染色体为 XX，理论上应该有两条 X 染色体，正常情况下 $|Z_X| \sim 0$ ；而在 $|Z_X| > 2.5$ 时，则意味着胎儿或母体 X 染色体异常以及系统测量错误等因素，一个显著异常的 Z_X 值表明本次检测的整个流程可能从根上就错了，因此基于此检测得出的任何结论都不可信；而我们假设 C_X 是 **X 染色体的浓度**（W 列），即 X 染色体游离 DNA 占总游离 DNA 的比例，浓度过高或过低都可能是异常信号，我们取 0.5% 到 4.0% 为一个常见的经验区间并进行数据的剔除，具体公式如下：

$$QC_2 = I(|Z_X| \leq 2.5) \cdot I(0.5 \leq C_X \leq 4.0) \quad (33)$$

由此可以排除不适合后续建模的数据。

5.4.3 模型的建立

首先，对于预处理好的数据，我们构建的**综合异常指数** AI_j 如下所示：

$$AI_j = w_1 \cdot I(|Z_j| > 3) + w_2 \cdot \left(\frac{|Z_j| - 3}{3} \right) + w_3 \cdot D_j + w_4 \cdot \left(\frac{|GC_j - 50|}{10} \right) \quad (34)$$

对于**第一项**，在统计学中 $|Z_j| > 3$ 意味着事件发生的概率极小（ $P < 0.0027$ ），通常被视为异常的决定性证据。只要 Z 值超过 3，这一项就会贡献一个固定的值 w_1 ，迅速拉高 AI_j 分数，它确保了所有显著的异常都能被捕获，其核心思想来源于题中所给的 Z-score 计算公式：

第一项只告诉我们是或否，而**第二项**量化了异常的程度，使得 AI_j 分数能够对异常信号的强度做出连续响应。

第三项则引入了**基于染色体长度的读段比例偏差** D_j 作为独立的异常证据。由于 NIPT 技术的根本原理是：如果胎儿染色体数量异常，那么母体血液中来自这条异常染色体的游离 DNA 片段的比例就会显著偏离其基于染色体长度预期的理论比例。具体表示如下：

$$D_j = \left| \frac{(O_j/R_{\text{total}})}{\hat{p}_j} - 1 \right|, j \in \{13, 18, 21\} \quad (35)$$

O_j/R_{total} 是观测到的读段比例，即实际比对到染色体的读段数占总有效读段数的比例，是测量值。 $\hat{p}_j$ 是预期（理论）的读段比例，是基于“测序读段在基因组上均匀分布”的理想假设下的预期值，是正常情况的基线。传统的 NIPT 分析主要依赖 Z 值。Z 值虽然是一个优秀的统计量，但它依赖于对照群体的均值和标准差；而我们模型的 D_j 提供了一个不依赖于外部对照群体的、基于样本内部信息的生物学证据。它将 Z 值的统计异常与读段数量的物理异常直接联系了起来。

第四项作为**数据质量惩罚项**，该项不是异常信号，而是起修正作用。GC 含量显著偏离 50% 意味着测序数据存在偏好性，这会影响 Z 值和 D_j 计算的准确性。

对于每一项的权重： w_1 、 w_2 、 w_3 、 w_4 ，我们采用**主成分分析法（PCA）**来进行确认。PCA 是一种用于降维和识别数据中潜在模式的统计方法，其目标是找到一组新的变量（主成分），这些变量是原始变量的线性组合，并且能够捕获数据中的最大方差。能够最大程度解释这些指标总体变异的线性组合即可视为相对贡献权重。

首先，对于每一个样本（每一位女胎孕妇的每一次检测），我们为其每一条目标染色体（ $j=13, 18, 21$ ）构建一个特征向量。最终得到一个大小为 $(n_{\text{samples}} \times 4)$ 的矩阵 X：

$$X = \begin{bmatrix} Z_{13}^1 & D_{13}^1 & |GC_{13}^1 - 50| & I(Z_{13}^1 > 3) \\ Z_{18}^1 & D_{18}^1 & |GC_{18}^1 - 50| & I(Z_{18}^1 > 3) \\ Z_{21}^2 & D_{21}^2 & |GC_{21}^2 - 50| & I(Z_{21}^2 > 3) \\ Z_{13}^2 & D_{13}^2 & |GC_{13}^2 - 50| & I(Z_{13}^2 > 3) \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix} \quad (36)$$

由于四个指标的量纲和尺度完全不同（例如 $|Z|$ 的值可能在 0-10 之间，而 $|GC-50|$ 在 0-10 之间， D 可能小于 1， $I(\cdot)$ 是 0 或 1），必须进行标准化，使每个特征均值为 0，标准差为 1。

$$X_{\text{standardized}} = \frac{X - \mu}{\sigma} \quad (37)$$

之后，对标准化后的数据矩阵 $X_{\text{standardized}}$ 进行 PCA 分解。PCA 会找到一组特征向量（定义主成分方向）和对应的特征值。在数学上即求解的是协方差矩阵 $\frac{1}{n-1}X^T X$ 的特征值和特征向量。

之后，提取到的第一主成分的载荷（即特征向量）为

$$\text{loadings}_{\text{PC1}} = [l_{|Z|}, l_D, l_{|GC-50|}, l_{I(Z>3)}] \quad (38)$$

由于载荷可能有正有负，但权重通常取正值。我们取其绝对值，然后进行归一化，使其和为 1，从而得到最终的权重。

$$\begin{aligned} w_{|Z|} &= \frac{|l_{|Z|}|}{|l_{|Z|}| + |l_D| + |l_{|GC-50|}| + |l_{I(Z>3)}|} \\ w_D &= \frac{|l_D|}{|l_{|Z|}| + |l_D| + |l_{|GC-50|}| + |l_{I(Z>3)}|} \\ w_{|GC-50|} &= \frac{|l_{|GC-50|}|}{|l_{|Z|}| + |l_D| + |l_{|GC-50|}| + |l_{I(Z>3)}|} \\ w_{I(Z>3)} &= \frac{|l_{I(Z>3)}|}{|l_{|Z|}| + |l_D| + |l_{|GC-50|}| + |l_{I(Z>3)}|} \end{aligned} \quad (39)$$

在我们的数据预分析中，我们还发现，高 BMI 孕妇的血浆中胎儿游离 DNA 比例通常较低，这就意味着有效信号弱，背景噪声高，从而导致 Z 值统计量的误差增大。因此，对于高 BMI 的样本，我们需要更强、更显著的异常证据（更高的 AI_j ）才会将其判定为异常，那么我们引入了一个**阈值缩放因子 β** 来补偿高 BMI 带来的高误差问题，具体表示如下：

$$\beta = 1 + \alpha \cdot (\text{BMI} - \text{BMI}_{\text{median}}) \quad (40)$$

同时，将原有的阈值 θ 进行缩放 $\theta' = \beta \cdot \theta$ ，最后根据下式进行女胎是否异常的判定。

$$\text{Result} = \begin{cases} \text{异常（高风险）}, & \text{if } \max(AI'_{13}, AI'_{18}, AI'_{21}) > \theta' \\ \text{正常（低风险）}, & \text{otherwise} \end{cases} \quad (41)$$

5.4.4 模型的求解与检验

经过代码搭建与运算，我们首先得到了预处理后的数据，再将预处理后的数据放入**多指标加权综合评分模型**中进行分析，得到各权重 $w_1 = 0.395$ 、 $w_2 = 0.184$ 、 $w_3 = 0.312$ 、 $w_4 = 0.109$ 。

因此，女胎异常异常判定可明确表示为以下步骤：

1. 对于每一次检测，首先进行质量控制和 X 染色体一致性检查，剔除不满足预处理条件的样本：

2. 对通过质控的样本，分别计算其 13、18、21 号染色体的综合异常指数：

$$AI_j = 0.395 \cdot I(|Z_j| > 3) + 0.184 \cdot \left(\frac{|Z_j| - 3}{3} \right) + 0.312 \cdot D_j + 0.109 \cdot \left(\frac{|GC_j - 50|}{10} \right) \quad (42)$$

3. 根据孕妇 BMI 对判定阈值进行动态调整，以补偿高 BMI 带来的测量不确定性；
4. 比较三条目标染色体（13, 18, 21）的最大综合异常指数与调整后的阈值，即可判定女胎是否异常。

下面，我们根据附件中表格给的试以女胎孕妇的 21 号、18 号和 13 号染色体非整倍体（AB 列）为判定结果，分别计算其召回率和准确率，进一步验证模型的可靠性；

其中，召回率是指在所有真正异常的样本中，该模型找出的样本的比率；准确率是指该模型找出的异常样本中，真正异常的样本占这些样本的比率。

我们取了许多某一次检测结果为非整倍体的孕妇的不同检测次数时的相关指标带入模型，来判断其是否为女胎异常，从而验证模型的准确性。可以将结果汇总为以下表格（只取了前 20 项作为展示）：

表 5.7: 问题四模型的验证结果（部分）

序号	女胎孕妇编号	自己的第几次检测	是否为女胎异常	缩放后的 θ' 值	AI_j	模型检测结果	是否正确
01	B004	1	否	0.845	0.647	否	√
02	B004	2	否	0.754	0.613	否	√
03	B004	3	是	0.884	0.862	否	×
04	B004	4	是	0.947	0.976	是	√
05	B005	1	否	0.965	0.828	否	√
06	B005	2	否	0.921	0.835	否	√
07	B005	3	否	1.132	0.95	否	√
08	B005	4	是	1.011	0.885	否	×
09	B007	1	否	0.911	0.996	是	×
10	B007	2	是	0.937	0.964	是	√
11	B007	3	否	0.861	0.75	否	√
12	B007	4	否	0.752	0.741	否	√
13	B011	1	否	0.986	1.017	是	×
14	B011	2	否	0.965	0.828	否	√
15	B011	3	否	1.101	0.953	否	√
16	B011	4	否	1.132	0.95	否	√
17	B014	3	否	0.987	0.865	否	√
18	B014	4	否	0.985	0.741	否	√
19	B014	5	否	0.965	0.828	否	√
20	B014	6	否	0.785	0.895	是	×

我们总共进行了 100 次对模型的验证，其中共判断出了 36 次异常情况，而真正异常的总共有 76 次，因此模型召回率约为 47.3%，有一定参考价值；其中有 84 次正确数据；因此模型准确率约为 84%，由此可证明，该模型对于女胎异常判定的准确率较高，具有一定的实际价值。

六、模型评价、改进与推广

6.1 模型的优点

1. 精准刻画非线性效应与交互作用

采用 Beta 分布 - 贝叶斯分层广义加性混合模型，通过贝叶斯框架实现孕周、BMI 对 Y 染色体浓度的非线性效应建模，并量化交互作用的统计显著性。其回归平方和（SSR）为 0.416，说明模型能够较良好地捕捉变量的大部分变化。以及对比其他模型下的贝叶斯因子（BF），更加说明了其优良性。

2. 量化个体差异与不确定性

随机截距项的标准差 σ_u^2 的后验均值为 0.132，有效捕捉同一孕妇多次检测的个体间变异，可知我们之前引入随机效应处理重复测量数据结构是必要且显著的。贝叶斯推断输出参数后验分布，为临床决策提供风险范围参考。

3. 临床检测时点优化

该模型实现高 BMI 群体分层推荐，自动根据数据推断出最佳分组并给出每一最佳 BMI 区间建议的最佳 NIPT 时点，满足“精准时点选择 + 异常识别”双维度需求。

6.2 模型的缺点

1. 罕见分组的小样本泛化性有限

对于极端高 BMI ($BMI \geq 40$) 这类临床罕见分组（在研究数据中占比仅约 2%），当单组有效样本量不足 30 例时，DP-GMM 的聚类算法易因数据稀疏性导致分组边界的泛化能力下降，使最佳检测时点的推荐结果在小样本场景下波动幅度达 ± 1.2 周。

3. 检测误差的异质性未充分区分

模型假设检测误差服从全局高斯分布，但未针对不同测序平台的系统误差异质性进行细化，临床中高端测序仪的随机误差标准差较基层便携式快检设备低很多，该简化假设会导致极端 Y 染色体浓度值的判定阈值在“跨设备检测”场景下出现偏差。

6.3 模型的改进与推广

1. 改进方向：

引入深度学习（如注意力机制）增强复杂模式学习；通过集成学习提升大规模数据表现；纳入年龄、妊娠史等更多临床因素，或输入高维数据，提升预测精度。

2. 模型推广：

可拓展至肿瘤标志物监测、慢性病风险评估等“生物学-环境因素交互”场景；还能结合不同地区、人群特征本地化优化，提高适用性。

七、参考文献

- [1] 施炜慧, 徐晨明. 无创产前检测在产科母体并发症和合并症诊断中的应用价值[J]. 实用妇产科杂志, 2025, 41(08): 617-620.
- [2] 王晓华, 许昊, 锁岚, 等. 基于广义加性混合模型(GAMM)的沙柳特征因子动态变化[J]. 中南林业科技大学学报, 2024, 44(09): 60-70+104. DOI: 10.14067/j.cnki.1673-923x.2024.09.007.
- [3] 陈仲. 基于狄利克雷过程混合模型的城市活动聚类方法研究[J]. 交通运输系统工程与信息, 2020, 20(06): 247-252. DOI: 10.16097/j.cnki.1009-6744.2020.06.033.
- [4] Zhang X, Li G, C. Liu C, et al. Tucker tensor factor models: Matricization and mode-wise PCA estimation[J/OL]. Science China Mathematics, 1-52
- [5] 朱陆陆. 蒙特卡洛方法及应用[D]. 华中师范大学, 2014.
- [6] 张鹏, 莫伟英, 蒙明慧, 等. 无创产前检测对性染色体非整倍体检出情况的影响及相关伦理思考[J]. 中国临床新医学, 2025, 18(06): 690-695.
- [7] 彭鼎. 狄利克雷过程在分段自回归模型中的应用[D]. 贵州师范大学, 2025. DOI:10.27048/d.cnki.ggzsu.2025.000703.
- [8] GPT, o4, OpenAI, 2025-09-05
- [9] DeepSeek, R10528, 深度求索(DeepSeek) 2025-09-05
- [10] Doubao, 1.5-pro, 字节跳动, 2025-09-05